

蒋帅

✉ sfpotato@outlook.com · ☎ (+86) 152-2261-0739 · 📄 blog.Corleo

🎓 教育背景

中山大学, 广州, 广东	2019 – 2022
硕士 信息与通信工程	
河北工业大学, 北辰, 天津	2015 – 2019
学士 电子与信息工程	

👨‍💻 项目经历

腾讯科技有限公司深圳	2022 年 7 月 – 至今
------------	-----------------

AI PaaS 建设

Go, Python, C++

AI 模型推理服务化与 PaaS 平台建设

- 将 Embedding 推理服务从 *FastAPI* 迁移至 *Triton Inference Server*, 通过 *dynamic batching* 与 *warm_up* 预热消除冷启动, 算力资源消耗降低 20%+
- 针对 TTS 流式推理链路, 引入异步读写缓冲区将音频生成与数据传输并行化, 首包耗时降低 200ms
- 通过封装 *io.Reader* 在流式传输层透明拦截数据, 以非侵入方式实现 ChatGPT 代理服务的访问记录落库与计费, 业务逻辑零改动

混元助手项目孵化

Go

LLM 推理及搜索增强底层能力的路由与接入层建设

- 优化服务链路生命周期管理, 实现服务终止时下游资源的即时释放, 提升整体吞吐量
- 实现异步流式内容检测, 消除检测服务对推理链路的阻塞, 降低客户端回答延迟
- 在搜索增强场景中, 基于滑动窗口在输出端实现流式引用插入, 避免 URL 占用推理 token

多模态数据研效平台

Go, Python

面向多模态模型训练的数据处理与管理平台

- 主导平台整体架构设计, 构建基于 DAG 的算子调度引擎, 支持多模态数据处理任务的依赖编排与并发执行
- 引入 *DuckDB* 替代传统关系型方案, 利用列式存储特性实现数据集的高效索引与多维聚合查询
- 基于 *Starlet* 设计统一数据格式转换层, 以适配器模式解耦业务数据结构与平台处理能力, 显著降低新业务接入成本

⚙️ 专业技能

- 熟悉数据结构与算法, LeetCode 常年 Guardian 段位
- 掌握计算机网络、操作系统等计算机专业基础知识
- 熟悉 Go 语言, 掌握 *Context*、*goroutine* 等底层原理, 熟悉并发编程与微服务治理
- 熟悉 Redis 在缓存、分布式锁及消息队列场景下的工程实践
- 熟悉 Python 语言及 AI 推理服务生态, 具备 *Triton Inference Server* 部署与性能调优经验

💖 个人荣誉

前 100, TPC 腾讯程序设计竞赛	2022 年 11 月
腾讯技术突破奖 (混元大模型联合项目团队)	2023 年 12 月